

计算机视觉 HW2 实验报告

小组信息

- 成员:潘越
- 学号:23307140058
- Github repo: <https://github.com/yvepan/CV-hw2-panyue>
- 模型权重网盘地址: https://drive.google.com/file/d/19YITjP_QeCgeC1rVTkM4qRmJJ8zOImK4/view?usp=drive_link
- 权重说明: GitHub 仓库不包含模型权重; 网盘压缩包中包含任务 1、任务 2 和任务 3 的全部 `best.pt` 权重。
- 权重压缩包内容:
 - 任务 1: `resnet18_imagenet_best.pt`、`resnet18_random_init_best.pt`、`resnet18_cbam_best.pt`、`swin_t_imagenet_best.pt`
 - 任务 2: `yolo8n_visdrone_best.pt`
 - 任务 3: `unet_ce_best.pt`、`unet_dice_best.pt`、`unet_ce_dice_best.pt`

任务 1: 微调 ImageNet 预训练 CNN 实现宠物识别

1.1 任务目标

- 数据集: Oxford-IIIT Pet Dataset。
- 类别数: 37 类宠物。
- 目标: 比较 ImageNet 预训练、随机初始化、注意力模块和 Transformer backbone 对分类准确率的影响。
- 评价指标: 验证集 Accuracy。

1.2 数据与训练设置

- 官方 `trainval`: 3680 张, 用作训练集。
- 官方 `test`: 3669 张, 用作验证/测试集。
- 输入尺寸: 224x224。
- 标准化: ImageNet mean/std。
- 数据增强:
 - `RandomResizedCrop`
 - `RandomHorizontalFlip`
 - `ColorJitter`
- 训练硬件: NVIDIA GeForce RTX 3080 Ti Laptop GPU。

1.3 模型与超参数


实验	初始化	模型	注意力	参数量	batch size	learning rate	epoch	loss
baseline	ImageNet	ResNet-18	none	11.20M	32	head 1e-3 / base 1e-4	20	CE + label smoothing
random-init	随机	ResNet-18	none	11.20M	32	1e-3	20	CE + label smoothing
cbam	ImageNet	ResNet-18	CBAM	11.28M	32	head 1e-3 / base 1e-4	20	CE + label smoothing
swin-t	ImageNet	Swin-T	none	27.55M	16	head 5e-4 / base 5e-5	20	CE + label smoothing

补充设置：

- baseline 将 ResNet-18 最后一层全连接层替换为 37 类输出。
- baseline 和 CBAM 实验前 2 个 epoch 冻结 backbone，之后整体微调。
- 优化器：AdamW。
- weight decay：1e-4。
- 学习率调度：CosineAnnealingLR。

1.4 实验结果

实验	best epoch	val accuracy
ResNet-18 ImageNet baseline	13	0.8610
ResNet-18 random init	20	0.4050
ResNet-18 + CBAM	9	0.8673
Swin-T ImageNet	5	0.9302



1.5 结果分析

- **预训练收益明显**：ResNet-18 从随机初始化的 0.4050 提升到 0.8610，说明在 Oxford-IIIT Pet 这种中等规模细粒度分类任务上，ImageNet 预训练特征比从零学习更稳定。
- **CBAM 有轻微提升**：ResNet-18 + CBAM 达到 0.8673，比 baseline 高 0.0063，参数量只增加约 0.08M。由于本实验没有做多随机种子重复，0.63 个百分点的提升不应被解释为严格显著优势，更合理的结论是：CBAM 在很小参数增量下表现出潜在增益。
- **Swin-T 效果最好**：Swin-T 达到 0.9302，是任务 1 中最优结果。相比 ResNet-18，Swin-T 的参数量和训练成本更高，但在细粒度品种识别上取得了更高的验证集 accuracy。
- **性能与成本权衡**：
 - ResNet-18 更轻量，适合资源受限场景。
 - Swin-T 准确率更高，但参数量和训练成本更大。

1.6 分类误差与结论边界

任务 1 的主要结论由四组同一数据划分上的 accuracy 支撑，但 accuracy 只能反映总体正确率，不能直接说明错误发生在哪些品种之间。Oxford-IIIT Pet 的 37 个类别中包含外观接近的猫狗品种，因此剩余错误更可能集中在细粒度视觉差异上，例如毛色、脸型、耳形或姿态相近的类别。由于当前报告没有保存逐图预测样例和混淆矩阵，本节不进一步声称某一类错误占主导。

因此，本任务中“预训练有效”和“Swin-T 最优”是由当前验证集数值直接支持的结论；“CBAM 有稳定优势”则证据不足，只能表述为低成本潜在改进。

任务 2：场景目标检测与视频多目标跟踪

2.1 任务目标

- 数据集：VisDrone2019-DET。
- 检测模型：YOLOv8n。
- 跟踪方法：YOLOv8 检测结果 + ByteTrack。
- 视频任务：
 - 对测试视频逐帧检测。
 - 为目标分配 Tracking ID。
 - 分析遮挡和 ID 跳变。
 - 统计越线目标数量。

2.2 检测数据处理


- 原始标注格式： `x,y,w,h,score,category,truncation,occlusion`。
- 转换方式：
 - 忽略 `category=0` 的 ignored regions。
 - 其余 10 类转换为 YOLO 格式。
- 类别映射：
 - pedestrian
 - people
 - bicycle
 - car
 - van
 - truck
 - tricycle
 - awning-tricycle
 - bus
 - motor
- 转换后数据规模：
 - 训练集：6471 张图像。
 - 验证集：548 张图像。


2.3 检测训练设置

项目	设置
模型	YOLOv8n
输入尺寸	640
batch size	16
epoch	50
iteration/epoch	约 405
优化器	AdamW
初始学习率	1e-3
weight decay	5e-4
best 权重	已上传至网盘压缩包中的 task2/yolov8n_visdrone_best.pt

2.4 检测结果

指标	结果
best mAP50	0.2993
best mAP50-95	0.1687





主要观察：

- `box_loss`、`cls_loss` 和 `dfl_loss` 在训练过程中整体下降。
- mAP 在训练中后期逐渐进入平台期。
- mAP50-95 只有 0.1687，主要原因包括：
 - VisDrone 目标小且密集。
 - 夜间/远景图像中目标边界较难定位。
 - YOLOv8n 模型容量有限。
- mAP50 与 mAP50-95 的差距说明模型对不少目标可以做到粗定位，但在更高 IoU 阈值下的精确框定位能力不足。这与 VisDrone 的小目标、密集遮挡和远景拍摄特点一致；考虑到 YOLOv8n 是轻量模型，该结果更体现了计算成本与检测精度之间的折中。
- 训练曲线已通过 `scripts/export_to_swlab.py` 导入 SwanLab，可展示 loss、mAP、precision 和 recall。

2.5 测试视频处理

- 原始视频：180386-864121573_medium.mp4。
- 场景：高空路口夜景。
- 原始属性：
 - 分辨率：2560x1440。
 - 帧率：59.94 FPS。
 - 总帧数：1895。

- 时长: 31.61 s。
- 作业要求测试视频为 10-30 s，因此截取前 30 s。
- 处理后视频：
 - 路径: `results/task2/task2_test_30s_720p.mp4`
 - 分辨率: 1280x720。
 - 帧率: 25 FPS。
 - 帧数: 750。
 - 时长: 30.00 s。


2.6 跟踪与越线计数结果

指标	结果
测试视频	<code>results/task2/task2_test_30s_720p.mp4</code>
视频时长	30.00 s
视频帧数	750
跟踪记录数	25253
越线目标总数	38
ID 分析帧段	250-253
可能 ID 跳变次数	2

实现方式:

- 使用训练好的 YOLOv8n 权重逐帧检测。
- 使用 ByteTrack 进行目标关联和 ID 分配。
- 输出检测框、类别、置信度和 Tracking ID。
- 本地复现时，跟踪结果保存到 `results/task2/tracking_final/tracks.csv`。
- 本地复现时，可视化视频保存到 `results/task2/tracking_final/tracked.mp4`。

越线计数设置:



- 虚拟线位置: (0.05, 0.64) -> (0.95, 0.64)。
- 坐标为归一化坐标。
- 该线覆盖画面中下部的马路和人行横道区域。
- 判定规则: 同一 Tracking ID 的框中心点跨越虚拟线两侧时计数。
- 去重规则: 同一 ID 只计数一次。

需要注意的是，越线计数依赖 Tracking ID 的时间连续性。如果目标在过线前后发生 ID switch，同一真实目标可能被重复计数，也可能因为轨迹断裂而漏计。因此，38 个越线目标应理解为当前检测-跟踪流水线下的自动统计结果，而不是人工标注的绝对真值。

2.7 遮挡与 ID 跳变分析



分析帧段: 第 250-253 帧。



帧号	跟踪目标数
250	39
251	40
252	31
253	32

相邻帧 ID 变化:

帧段	保持 ID	丢失 ID	新增 ID	可能 ID 跳变
250 -> 251	35	4	5	无

帧段	保持 ID	丢失 ID	新增 ID	可能 ID 跳变
251 -> 252	31	9	0	无
252 -> 253	26	5	6	3479 -> 2416; 3803 -> 3549





Task 2 ID-switch local evidence: frame 252 -> 253

Possible IDswitch: 3479 -> 2416



Possible IDswitch: 3803 -> 3549



分析结论:

- 大多数车辆目标可以保持连续 ID。
- 行人、小目标和画面边缘目标更容易短时丢失。
- 第 252 -> 253 帧出现 2 个可能 ID 跳变: 3479 -> 2416 和 3803 -> 3549。局部放大图显示, 旧 ID 消失后, 相近位置重新出现了新的 Tracking ID。
- 夜间光照、密集遮挡、目标尺度小以及检测置信度波动是跟踪不稳定的主要原因。这也解释了为什么计数结果需要作为自动统计结果看待, 而不能直接等同于人工核验后的 ground truth。

任务 3：从零搭建 U-Net 图像分割

3.1 任务目标

- 从零实现 U-Net，不使用预训练权重。
- 数据集：Oxford-IIIT Pet segmentation mask。
- 输出类别：3 类像素标签。
- 对比损失函数：
 - Cross-Entropy Loss
 - Dice Loss
 - Cross-Entropy + Dice Loss
- 评价指标：验证集 mIoU。

3.2 网络结构

- 编码器：4 次下采样。
- 每个编码层： Conv-BN-ReLU-Conv-BN-ReLU 。
- 解码器：转置卷积上采样。
- Skip Connection：解码阶段拼接同尺度编码器特征。
- 输出层：1x1 卷积，输出 3 类 logits。
- 参数量：7.76M。

3.3 数据与训练设置

项目	设置
训练集	Oxford-IIIT Pet trainval , 3680 张
验证集	Oxford-IIIT Pet test , 3669 张
输入尺寸	192x192
batch size	16
epoch	30
iteration/epoch	约 230
优化器	AdamW
学习率	1e-3
weight decay	1e-4

3.4 损失函数比较

Dice 系数直接度量预测区域和真实区域的重叠程度：

$$Dice = \frac{2|P \cap G|}{|P| + |G|}$$

对应的 Dice Loss 为：


$$\mathcal{L}_{Dice} = 1 - Dice$$

在多类别分割中，本实验按类别计算 Dice 后取平均：


$$\mathcal{L}_{Dice} = 1 - \frac{1}{C} \sum_{c=1}^C \frac{2 \sum_i p_{i,c} g_{i,c} + \epsilon}{\sum_i p_{i,c} + \sum_i g_{i,c} + \epsilon}$$

Cross-Entropy 更关注每个像素的分类是否正确，Dice Loss 则直接优化区域重叠，因此后者通常更不容易被大面积背景像素主导。

损失函数	best epoch	val mIoU
Cross-Entropy	29	0.7615
Dice	27	0.7720
Cross-Entropy + Dice	29	0.7739



3.5 结果分析



- **Dice Loss 优于 Cross-Entropy:**

- CE: 0.7615。
- Dice: 0.7720。
- 提升: 0.0105。

- **组合损失效果最好:**

- CE + Dice 达到 0.7739。
- 相比 CE 提升 0.0124。

- **原因分析:**

- CE 更关注逐像素分类。
- Dice 直接优化区域重叠，更适合前景/背景不均衡的分割任务。
- CE + Dice 同时保留像素级稳定性和区域级优化目标。

- **可视化观察**：分割对比图显示，Dice 类目标在前景区域完整性上通常更稳定；CE + Dice 在边界和区域重叠之间取得了相对均衡的结果。不过在前景被遮挡、边界复杂或主体贴近图像边缘时，三种损失都会出现局部边界偏移或前景缺失。
- 本地训练时会在 `results/task3/*/visualizations/` 生成分割可视化样例；本报告额外整理了同一批样例在 CE、Dice 和 CE + Dice 三个权重下的横向对比图。

复现命令

数据准备

```
python scripts/setup_datasets.py --root .  
python scripts/prepare_visdrone.py --root datasets/VisDrone --out datasets/visdrone_yolo
```

任务 1 训练

```
python scripts/train_task1.py --config configs/task1_resnet18.yaml  
python scripts/train_task1.py --config configs/task1_resnet18_random_init.yaml  
python scripts/train_task1.py --config configs/task1_resnet18_cbam.yaml  
python scripts/train_task1.py --config configs/task1_swin_t.yaml
```

任务 2 检测与跟踪

以下命令用于本地复现，需先准备 VisDrone 数据集、测试视频，并将下载的 YOLO 权重放到命令中的 `--weights` 路径。

```
python scripts/train_task2_yolo.py --config configs/task2_yolov8.yaml  
python scripts/prepare_task2_clip.py --src 180386-864121573_medium.mp4 --dst  
results/task2/task2_test_30s_720p.mp4 --duration 30 --fps 25 --width 1280  
python scripts/track_task2.py --weights  
runs/detect/results/task2/visdrone_yolov8/weights/best.pt --video  
results/task2/task2_test_30s_720p.mp4 --out results/task2/tracking_final --line 0.05 0.64  
0.95 0.64 --analyze-start 250 --analyze-len 4
```

任务 3 训练

```
python scripts/train_task3.py --config configs/task3_unet_ce.yaml  
python scripts/train_task3.py --config configs/task3_unet_dice.yaml  
python scripts/train_task3.py --config configs/task3_unet_ce_dice.yaml
```

SwanLab 可视化

```
python scripts/export_to_swanlab.py --mode local --project cv-hw2 --logdir swanlog
```

总结

- 任务 1 完成了宠物分类实验：
 - ImageNet 预训练显著优于随机初始化。

- CBAM 带来轻微提升，但由于只报告单次实验，应理解为低成本潜在增益。
 - Swin-T 取得最高 Accuracy，达到 0.9302。
- 任务 2 完成了检测、跟踪、遮挡分析和越线计数：
 - YOLOv8n 在 VisDrone 上取得 mAP50 0.2993。
 - 最终测试视频长度为 30.00 s，满足作业要求。
 - 跟踪阶段产生 25253 条记录，越线计数为 38。
 - 第 250-253 帧中检测到 2 次可能 ID 跳变；因此越线计数应作为自动统计结果，而不是人工真值。
- 任务 3 完成了从零实现 U-Net：
 - CE + Dice 损失取得最佳 mIoU，达到 0.7739。
 - Dice 类损失更适合当前前景/背景不均衡的宠物分割任务。